

Dokumentacja wstępna

Zespół: Viktoriia Nowotka, Paweł Łasica

Temat: Iteracyjny trening dla niezbalansowanych zbiorów

Próbujemy poprawić jakość klasyfikacji niezbalansowanych zbiorów danych przy pomocy drzewa decyzyjnego w następujący sposób. Odkładamy 10% przykładów obu klas jako zbiór testujący. Z pozostałego zbioru tworzymy zbiór trenujący przez próbkowanie zbioru przykładów klasy większościowej tak, aby ich liczba była równa liczbie przykładów klasy mniejszościowej. Trenujemy klasyfikator. Następnie iteracyjnie:


- 1) określamy które z niewykorzystanych przykładów klasy większościowej zostały zaklasyfikowane nieprawidłowo;
- 2) losowo wybieramy z nich pewną liczbę przykładów;
- 3) dodajemy je do zbioru trenującego;
- 4) tworzymy ponownie i oceniamy klasyfikator - nowy model.

Jak zmienia się jakość kolejnych klasyfikatorów? Jak ma się ona do podejścia domyślnego?

Doprecyzowanie tematu projektu i zagłębienie się w problematykę zadania:

Niezbalansowany zbiór danych to taki, w którym jedna z klas ma znacznie więcej próbek niż druga. Zjawisko to znacznie utrudnia poprawne modelowanie zbioru i wymaga użycia odpowiedniego reżimu treningowego oraz metryk. W przeciwnym przypadku wytrenowany model może zostać wbrew rzeczywistości uznany za dobry.

Zgodnie z naszym rozumieniem zadaniem tego projektu jest porównanie metryk jakości modeli binarnych drzew decyzyjnych dla różnego stopnia niezrównoważenia zbioru treningowego.



Rys. 1 - Schemat algorytmu przepływu danych w dataacie dla tworzenia, uczenia i walidacji modeli

Precyzyjny opis algorytmu

Dla budowy drzew decyzyjnych postanowiono wykorzystać algorytm CART dla zadania klasyfikacji. Algorytm ten konstruuje drzewo decyzyjne poprzez rekurencyjny podział przestrzeni cech w sposób binarny dla danych liczbowych i kategoriowych. W każdym węźle drzewa wybierany jest taka funkcja podziału i próg, które minimalizują miarę nieczystości powstających podzbiorów według indeksu Gini:

$$Gini = 1 - (p_1^2 + p_2^2)$$

, gdzie:

- p_1 – udział klasy pozytywnej w węźle,
- p_2 – udział klasy negatywnej.

Algorytm CART:

1. dla wszystkich możliwych podziałów wybierany jest ten, który minimalizuje nieczystość klas,
2. dane są dzielone na dwa podzbiory (lewa gałąź jest $<$ progowi, prawa gałąź jest $\geq$ progowi),
3. proces jest powtarzany aż do spełnienia warunku stopu (minimalna liczba próbek w podziorze, jednolita klasa podzioru).

Zgodnie z wytycznymi zadania i planem eksperymentów, który jest opisany niżej, szczegółowy opis całego programu wygląda następująco:

Dla datasetu wykonać:

- 1) Stratyfikacja danych (10% danych (z obu klas) odkładane jest jako zbiór testowy, a pozostałe 90% stanowi zbiór treningowy)
- 2) Tworzenie bazowego drzewa M_0 (trenowany jest model CART na niezbalansowanym zbiorze, model oceniany jest na zbiorze testowym, wyniki zapisywane jako punkt odniesienia)
- 3) Under sampling danych (ze zbioru treningowego wybierane są wszystkie przykłady klasy mniejszościowej, losowo dobierana jest taka sama liczba przykładów klasy większościowej, powstaje zbalansowany zbiór treningowy)
- 4) Dla 25 uruchomień pętli:
 - a) Dla $n \text{ samples} \in \{0.5\%, 1\%, 2\%, 5\%, 10\%, 15\%, 25\%, 35\%, \text{reszta}\}$
 - i) trenowany jest nowy model $M_{i,j}$
 - ii) model jest oceniany na zbiorze testowym
 - iii) model klasyfikuje niewykorzystane wcześniej przykłady klasy większościowej
 - iv) wyznaczane są błędne klasyfikacje (false positives)
 - v) losowo wybieranych jest $n \text{ samples}$ przykładów z tej grupy
 - vi) wybrane przykłady są dodawane do zbioru treningowego
- 5) Zebranie uśrednionych wyników do tabeli

Plan eksperymentów

W danym projekcie skupiono się głównie na analizie wpływu stopnia niezrównoważenia danych na jakość klasyfikacji drzewa decyzyjnego oraz na ocenie skuteczności iteracyjnego podejścia do rozszerzenia zbioru treningowego po wykonaniu undersamplingu.

W celu przeprowadzenia eksperymentów zostaną wykorzystane 3 zbiory danych o różnym stopniu niezrównoważenia, co pozwoli zbadać wpływ struktury danych wejściowych na skuteczność klasyfikacji.

Dla każdego ze zbiorów danych zostanie przeprowadzone badanie hiperparametra $n_samples$: losowo wybierany procent false positives predykcji modelu, które powiększą zbiór danych treningowych modelu w następnej iteracji.

Aby zapewnić wiarygodność uzyskanych wyników i ograniczyć wpływ losowości, każdy eksperyment zostanie powtórzony 25 razy i analiza będzie dokonywana na uśrednionych wynikach.

Miary jakości modeli

Dla zadania binarnej klasyfikacji podstawową metryką oceny jakości modeli jest tablica pomyłek: true/false positives/negatives. Na podstawie tych czterech kategorii możemy także wyliczyć dokładność i błąd klasyfikatora.

$$Dokładność = \frac{TP + FP}{TP + FP + FN + TN}$$
$$Błąd = 1 - Dokładność = \frac{FN + TN}{TP + FP + FN + TN}$$

, gdzie:

- TP – poprawna klasyfikacja pozytywnej klasy,
- TN – poprawna klasyfikacja negatywnej klasy,
- FP – błędna klasyfikacja pozytywnej klasy,
- FN – błędna klasyfikacja negatywnej klasy.

Jednak te dwie miary dokładności nie są wyczerpujące dla oceny niezrównoważonych klas. Dla niezbilansowania zbiorów danych bardziej wyczerpujące są miary: czułość (true positive rate, TPR), false positive rate (FPR), precyzja i zagregowana miara F1-score.

$$TPR = \frac{TP}{TP + FN}$$
$$FPR = \frac{FP}{FP + TN}$$
$$Precyzja = \frac{TP}{TP + FP}$$
$$F1 = \frac{2 * Precyzja * TPR}{Precyzja + TPR}$$

Miara F1 jest szczególnie użyteczna dla analizy wyników w danym projekcie, ponieważ uwzględnia kompromis pomiędzy precyzją a czułością i pozwala lepiej ocenić rzeczywistą skuteczność modelu.

Opis zbiorów danych

Poniżej opisane zostały surowe zbiory danych. Przyjmujemy możliwość wykonania inżynierii cech oraz czyszczenia danych w celu poprawy wyników.

Credit Card Fraud Detection

Zbiór danych zawiera zanonimizowane dane nt. transakcji kartami kredytowymi. Zadaniem jest wykrycie oszustw płatniczych (fraud).

Liczba próbek	Liczba próbek klasy większościowej	Liczba próbek klasy mniejszościowej	Liczba atrybutów numerycznych	Liczba atrybutów kategoriycznych	% udziału klasy mniejsz	Źródło
284 807	284315	492	29	0	0.17%	Link

Give me some credit

Zbiór danych zawiera dane o sytuacji kredytowo-majątkowej klientów. Zadaniem jest zaklasyfikowanie, czy istnieje duże ryzyko defaultu kredytowego w ciągu dwóch lat przez danego klienta.

Liczba próbek	Liczba próbek klasy większościowej	Liczba próbek klasy mniejszościowej	Liczba atrybutów numerycznych	Liczba atrybutów kategoriycznych	% udziału klasy mniejsz	Źródło
150 000	139974	10026	10	0	7.16%	Link

Adult income

Zbiór danych zawiera dane o sytuacji majątkowo-życiowej. Zadaniem jest przypisanie kategorii zarobków każdej z osób w zbiorze.

Liczba próbek	Liczba próbek klasy większościowej	Liczba próbek klasy mniejszościowej	Liczba atrybutów numerycznych	Liczba atrybutów kategoriycznych	% udziału klasy mniejsz	Źródło
48 842	37155	11687	5	8	31.45%	Link